河南工学院
HENAN INSTITUTE OF TECHNOLOGY

毕 业 设 计 说 明 书

基于生成对抗网络的人脸修复系统的设计与实现

Design and Implementation of Face Restoration System Based on GANs

学 院 名 称 ： 计算机科学与技术学院

专 业 ： 数据科学与大数据技术

班 级 ： 数据科学 191

学 生 姓 名 ： 梁丰源

学 号 ： 1907381133

指 导 教 师 姓 名 ： 王镇威

指 导 教 师 职 称 ： 讲师

2023 年 6 月 5 日

毕业设计（论文）原创性声明和使用授权说明

原创性声明

本人郑重承诺：所呈交的毕业设计（论文），是我个人在指导教师的指导下进行的研究工作及取得的成果。尽我所知，除文中特别加以标注和致谢的地方外，不包含其他人或组织已经发表或公布过的研究成果，也不包含我为获得河南工学院及其它教育机构的学位或学历而使用过的材料。对本研究提供过帮助和做出过贡献的个人或集体，均已在文中作了明确的说明并表示了谢意。

作 者 签 名：_____　　日　　期：_____

指导教师签名：_____　　日　　期：_____

使用授权说明

本人完全了解河南工学院关于收集、保存、使用毕业设计（论文）的规定，即：按照学校要求提交毕业设计（论文）的印刷本和电子版本；学校有权保存毕业设计（论文）的印刷本和电子版，并提供目录检索与阅览服务；学校可以采用影印、缩印、数字化或其它复制手段保存论文；在不以营利为目的前提下，学校可以公布论文的部分或全部内容。

作者签名：_____　　日　　期：_____

基于生成对抗网络的人脸修复系统的设计与实现

摘要：近年来，随着计算机硬件行业的发展，尤其是GPU技术的进步，使得深度学习领域取得了巨大的进展。2014年，Ian GoodFellow首次提出了GAN算法（Generative Adversarial Nets），这一创新性算法使用两个神经网络——判别器和生成器，以训练生成器生成接近训练集的内容。自2017年起，学者们在原始版本的GAN算法基础上进行了更深入的研究，因此在2018年诞生了the-GAN-zoo项目，用以统计所有基于GAN的变种算法，其中包括就GFP-GAN算法（其中GFP指Generative Facial Prior，即生成性面部先验）。GFP-GAN算法重点关注使用面部几何先验进行盲脸修复。当下，人脸修复技术已被证实可以在诸多领域被应用。

本研究注意到，在历史研究领域存在大量上世纪初期的人像摄影作品，它们可以作为研究当时社会面貌的重要资料。然而，由于当时摄影技术条件落后，这些图像的清晰度过低，难以作为研究资料。

因此，本文基于GFP-GAN算法的思想，引入了生成性人脸先验（generative facial prior）对GAN算法进行了优化，用于修复这些低清晰度的人像。该系统实现了对图片中人像的定位和面部细节修复，相较于以往的人脸修复算法，修复结果在视觉上真实度更高，在图片修复的量化标准上（如峰值信噪比等）表现更好，并且具有用户友好的GUI界面。用户可以通过导入需要修复的含有人脸的图片，从而实现对大部分含有人脸图片的细节修复。

关键词：深度学习；生成对抗网络；计算机视觉；人脸修复

Design and Implementation of Face Restoration System Based on GANs

Abstract: In recent years, with the development of the computer hardware industry, especially the advancement of GPU technology, the field of deep learning has made great progress. In 2014, Ian GoodFellow first proposed the GAN algorithm (Generative Adversarial Nets), an innovative algorithm that uses two neural networks - a discriminator and a generator - to train the generator generate the content that closing to the training set.Since 2017, scholars have conducted more in-depth research on the original version of the GAN algorithm.This led the appearance of the-GAN-zoo project in 2018, which is used to count all variant algorithms based on GAN,which including GFP-GAN algorithm (where GFP refers to Generative Facial Prior). The GFP-GAN algorithm focuses on solving blind face restoration problem by Generative Facial Prior.At present,it has been proved that face restoration can be applied in many fields.

This study notes that there are a large number of portrait photographs from the early last century in the field of historical research, which can serve as important materials for studying the social appearance at that time. However, due to the backwardness of photographic technology at that time, these images have low clarity and are difficult to use as research materials.

Therefore, this paper optimizes the GAN algorithm based on the ideas of the GFP-GAN algorithm by introducing a generative facial prior to repair low-resolution portraits. The system achieves the localization and facial detail restoration of portraits in images. Compared to previous face restoration algorithms, the restoration results are more visually realistic and perform better on quantitative image restoration standards such as peak signal-to-noise ratio. Additionally, it has a user-friendly GUI interface. Users can import pictures containing faces which need to be repaired to achieve detailed restoration for most pictures containing faces.

Key words: Deep Learning; Generative Adversarial Networks; Computer Vision; Face Restoration

目录

第 1 章　绪论 1
1.1 课题研究的背景与意义 1
1.2 国内外研究现状及动态 1
1.3 论文组织结构 3
第 2 章　需求分析与数据预处理 4
2.1 需求分析 4
2.2 开发环境 4
2.3 数据集采集 5
2.4 数据集的处理 6
第 3 章　GAN 算法的设计与优化 7
3.1 生成对抗框架设计 7
3.1.1 训练初始化 8
3.1.2 判别器函数推导 8
3.1.3 生成器函数推导 9
3.1.4 迭代训练 9
3.2 算法框架优化 10
3.2.1 优化技术介绍 11
3.2.2 损失函数 12
第 4 章　前端设计与系统测试 14
4.1 前端设计 14
4.2 视觉效果对比 16
4.3 量化标准对比 17
4.4 量化标准测试流程及结果 18
第 5 章　总结及展望 20
参考文献 21
致谢 23

第 1 章　绪论

1.1 课题研究的背景与意义

人工智能[1]算法一直被认为是解决计算机视觉[2]问题的一个极具潜力和蕴含诸多可能性的发展方向。人脸修复作为计算机视觉研究领域的一个分支，被广泛应用于医疗、教育、司法、历史研究等诸多领域。

GAN 算法[3]作为一种无监督的结构化学习算法[4]，最初被寄希望于通过训练，使其两个神经网络之中的生成器和判别器不断迭代，进而使生成器函数的取值范围逼近于训练集的理论函数。之后 GAN 被认为是解决图像修复问题的有效算法，受到学界进一步的讨论，从而衍生出了 EBGAN、HiFaceGAN、GFPGAN 等一系列基于原始 GAN 的衍生算法。

本系统主要基于 GFPGAN 算法进行开发，通过使用优化的 GFPGAN 算法利用预训练的人脸生成对抗网络中封装的丰富多样的先验知识进行盲脸修复。模型修复出的图片具有较低的失真率和较高的清晰度，以及较为准确的面部分割特征，可以准确地针对正脸、侧脸等不同角度的人脸进行修复。相对于同类型算法对于面部五官和面部整体都分别保证了较低的损失。

1.2 国内外研究现状及动态

盲脸修复问题其本质上是一个盲问题。即在真实世界的人脸总是会受到未知程度的降质干扰，面对一个不存在于已知训练集的低质量人脸数据输入，模型实际上并不知道自己所要生成的高质量人脸应该是什么样的。其只能根据从训练数据中学习的知识结合低质量人脸的特征去生成符合模型训练经验的人脸。盲脸修复的输入和输出可以视为，输入一个较低维向量，经过神经网络处理后再输出一个高维向量，是一个结构化生成的无监督算法。

GAN 算法之前的结构化生成算法有以下三种难以解决的问题：(1)分类器难以自己训练出生成功能，这会导致其目标函数是一个难以求解的 arg 函数；(2)训练集因为数据数量有限所以是离散的数据，而真正希望生成器逼近的取值范围往往是一个连续的

高维区间，生成器在单独训练的过程中无法理解存在于离散数据之间的连续区间；(3)过往的结构化学习算法在关注生成结果(这里一般指高维向量)的整体性和关注生成结果的结构关联性之间存在矛盾。

GAN 算法和生成式对抗的概念，其基于两个结合的神经网络(neural networks)，分别是判别器(discriminator)和生成器(generator)，很好地解决了这些问题。GAN 模型对于图像生成领域的结构化学习算法所遇到的问题给出了有效的解决方案：(1)两个神经网络交错迭代，判别器不再需要自己训练生成功能；(2)判别器为生成器在训练过程中的梯度下降方向给出了更优的解决方案；(3)在训练过程中判别器负责降低图像整体结构上的损失，生成器负责增加图片中每个像素点与周围像素间的结构关联性。两者之间不再矛盾。

2014 年，Ian GoodFellow 首次提出了 GAN 算法和生成式对抗的概念，其基于两个结合的神经网络——判别器和生成器，有效地解决了上述问题。然而，由于当时硬件算力有限，生成式对抗算法并未被学界广泛关注。直到 2018 年 20 系主力图形处理器发布后，生成式对抗才开始被认为是一种高效解决计算机视觉领域问题的手段，相关研究论文也爆发式增加，ICASSP 历年论文关键词数据证明了这一趋势。

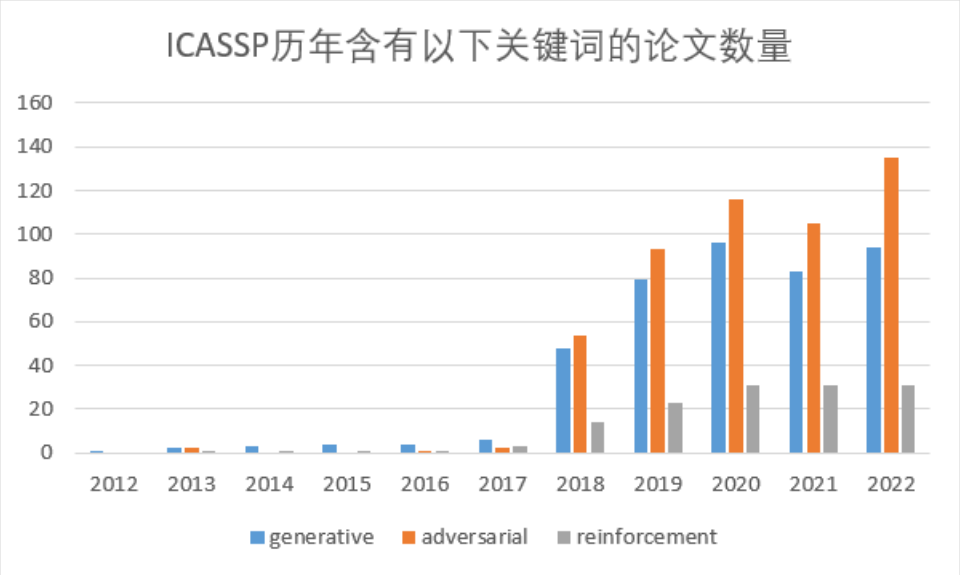

图 1.1 ICASSP 历年与生成式对抗相关的论文数量(reinforcement 作为对照组)[5]

此后，产生了一系列以 GAN 算法为基础的衍生算法。为了做出区分，Ian GoodFellow 以原始 GAN 算法目标函数同时具有 min 和 max 特点将其命名为 min max GAN[6]。截至 2018 年，衍生算法数量已超过 500 种。

2018	9	GraphSGAN	Semi-supervised Learning on Graphs with Generative Adversarial Nets
2018	9	IGMM-GAN	Coupled IGMM-GANs for deep multimodal anomaly detection in human mobility data
2018	9	MeRGAN	Memory Replay GANs: learning to generate images from new categories without forgetting
2018	9	SAM	Sample-Efficient Imitation Learning via Generative Adversarial Nets
2018	9	SiftingGAN	SiftingGAN: Generating and Sifting Labeled Samples to Improve the Remote Sensing Image Scene Classification Baseline in vitro
2018	9	SLSR	Sparse Label Smoothing for Semi-supervised Person Re-Identification
2018	9	Twin-GAN	Twin-GAN -- Unpaired Cross-Domain Image Translation with Weight-Sharing GANs
2018	9	WaveletGLCA-GAN	Global and Local Consistent Wavelet-domain Age Synthesis

图 1.2 部分基于 GAN 算法的衍生算法[7]

2021 年，NVIDA 发布 30 系主力显卡。此时，GPU 及其搭载的 CUDA 加速框架[8]已被认为是一种有效加速人工智能算法训练的方式。Tencent 研究团队结合过去人脸修复算法的经验，提出了 GFPGAN 算法[9]。其最大特点是包括一个降解去除模块（U-Net）和一个预先训练的 GAN（styleGAN）作为面部先验。修复后图片清晰度和五官结构损失明显优于同类型算法。

1.3 论文组织结构

全文研究除第一章以外的主要内容结构安排如下：

第二章，前期研究。本部分对系统进行了需求分析；介绍了在模型训练过程中使用的硬件环境和软件环境，并提供了对应的版本数据；介绍了模型在训练过程中使用的人脸图片数据集，以及对如何对数据集进行操作。

第三章，算法设计与分析。本部分主要介绍了作为本系统衍生基础的 GAN 算法的整体算法框架以及对于 GAN 损失函数的分析；除此之外本部分详述了本系统参照 GFPGAN 的部分设计思路在原有 GAN 基础上进行了哪些框架优化，

第四章，前端 UI 设计。本部分介绍了用户友好界面的设计结构，以及展示了界面的实际演示效果。

第五章，系统测试。本部分对模型的人脸修复效果与同类型算法的修复效果进行了横向视觉对比测试。通过图片修复评价计算程序对本系统的修复效果进行了量化测试，使用了评价图片修复算法的常用评价指标与同类型算法的测试数据进行了对比。

第六章，总结及展望。本部分总结了在课题设计过程中的收获和遇到的问题，并提出了笔者对本课题未来发展的展望。

第 2 章　需求分析与数据预处理

2.1 需求分析

为受到复杂未知退化的低清晰度人脸图片提供快捷可靠的面部细节修复和降质删除。包括但不限于为 AI 绘图提供有效的面部细节补充，以及为历史研究领域提供高质量的清晰化人脸修复。

由于 NVIDIA GeForce GTX 1660 Ti 不能满足开发条件，故尝试使用开源开发平台 Google Colaboratory 来进行模型的训练。

基于 PySimpleGUI[10]库设计用户友好的 GUI，可以任意选取需要修复的图片或一个文件夹中的所有图片。

为了测试本系统的性能，还将设计图形修复质量计算系统，采用 SSIM[11]、PSNR、LPIPS[12]三项常用的图像修复质量评判标准，将输出结果保存为 csv 格式，以此作为除肉眼观察之外的客观可量化的评判标准，并与同类型算法进行横向对比。

2.2 开发环境

如表 2.1 所示为开发环境所用到的硬件以及参数。

表 2.1 硬件开发环境

硬件名称	硬件规格
CPU	Intel(R) Core(TM) i5-9300H CPU @ 2.40GHz
GPU	NVIDIA GeForce GTX 1660 Ti NVIDIA Tesla T4 (Google Colaboratory)
Memory	8GB @ 2667Hz

如表 2.2 所示为开发环境用到的软件及参数。

表 2.2 软件开发环境

软件名称	软件版本
Operation System	Windows 11 22000.1817(21H2)
Anaconda	4.14.0
Python	3.9.2150.0
Pytorch	2.0.0
Numpy	1.20.0
CUDA	12.1
Argparse	3.9.2150.0
PySimpleGUI	4.60.4
lpips	0.1.4

2.3 数据集采集

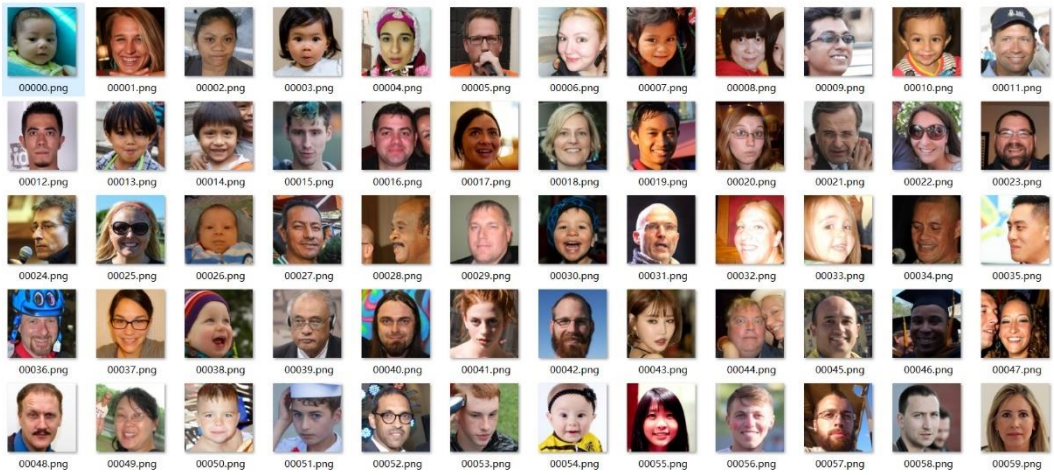

图 2.1 FFHQ 数据库中的部分数据

训练数据采用了 FFHQ 数据集[13]。FFHQ(Flickr-Faces-High-Quality)最初作为生成式对抗网络的基准而被创建，由 NVIDA 在 2019 年开源。其数据库中包含了 70000 张 1024*1024 张 PNG 格式的高清面部图片。更重要的是，他涵盖了不同的性别、年龄、肤色、表情、发型的人脸，还考虑到了各种各样的配饰，如眼镜、帽子、围巾等。这

对减少身份特征损失和面部器官特征损失有很大帮助。

但由于其数据规模太大，本文在训练模型时使用了标号 00000~09999 的数据。

2.4 数据集的处理

因为 FFHQ 数据库中只含有高清图片数据，而对于 GAN 算法还需要一组与高清图片相对的低清晰度图片来构成训练数据对，在这一过程中需要对高清图片进行降质操作。本文中使用了高斯模糊、下采样、高斯噪音、JPEG 压缩。具体参数如下。

表 2.3 降质操作具体参数

参数名称	数值	说明
blur_sigma	0.1~10	高斯模糊
downsample_range	0.8~8	下采样
noise_range	0~20	添加噪声
jpeg_range	60~100	JPEG 压缩

原版 GAN[3]在初次训练时使用高斯分布为未迭代的生成器分配参数和输入向量，生成器的初次生成结果作为低清晰度图片来构成训练数据对。本文使用了降质的高清化图片来构成训练数据对可以有效减少在训练之初的迭代次数。

第 3 章　GAN 算法的设计与优化

3.1 生成对抗框架设计

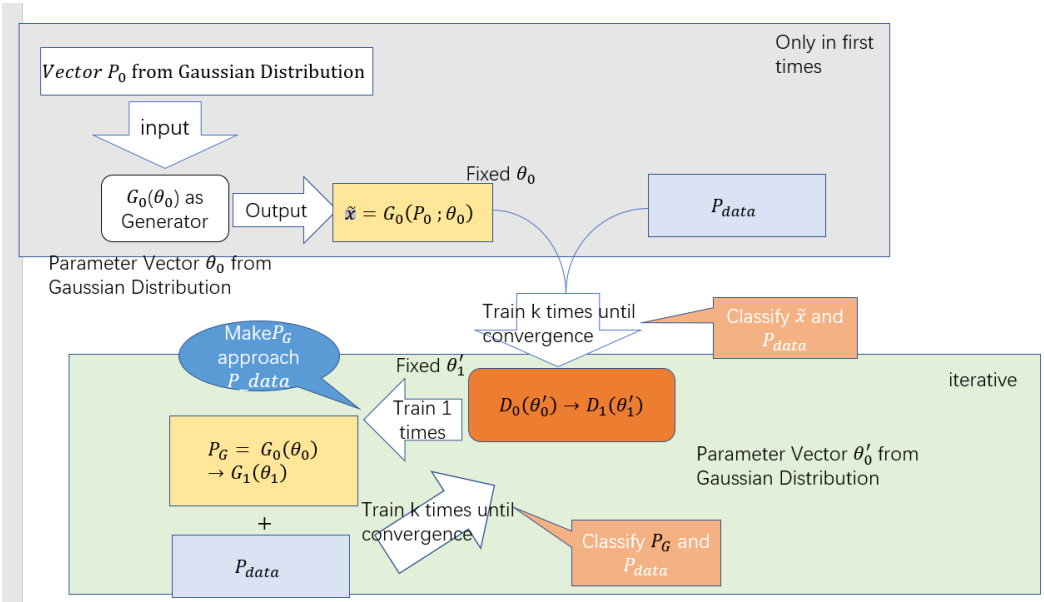

图 3.1 GAN 算法结构图

首先，假定算法要生成的人脸的定义域是一个存在于高维空间中的低维流形，它有一个固定的取值范围。我们把它定义为y，它代表着包含了所有现实中存在的人脸图像数据集的一个向量，可以从其中抽取数据但无法获知其具体的函数图像。将单个图像中的一个像素表示成 RGB 数据，那么对于 1024*1024 规格的图像，可以理解为一个 1024*1024 尺寸的矩阵，而整个数据集是一个包含了无数类似数据的高维向量。

一般在数学表达中会把神经网络抽象为一个拥有极多个权重和偏置的复杂函数。而根据泰勒定理，当一个多项式拥有足够多的项数，其理论上可以逼近任意任何光滑函数。生成器G(θ)的本质是一个神经网络，该算法期望通过足够多次的迭代来使得其输出结果P_G靠近y。

以往的方法是将生成器设计成一个高斯混合分布，把y也假设为一个混合高斯分布，通过极大似然估计法进行迭代，使得P_G的范围一步步靠近 y 的范围。在理想状态下，两者的函数图像最后会完全重叠。

然而在实际操作中这会导致模型最后生成的图像极其模糊，这是因为 y 其实是存

在于高维空间中的一个低维流形，而高斯混合分布在计算时无法顾及这一点，因此无论如何调整权重和偏置，都不可能逼近目标函数。除此之外，因为无法获得 y 真正的定义域公式。y 所代表的是所有现实中可能出现的人脸图像的集合，无法用任何已知的方法来获得其真实的表达函数，继而也无法计算一个数据项存在于其范围区间内的似然值。但是可以把 FFHQ 数据集看作是抽取自 y 空间的随机采样数据，其作为训练集被定义为P_{data}。

3.1.1 训练初始化

假设目标函数是：

$$\hat{y}\approx y，\hat{y}=\min_G \mathrm{Div}(P_G,P_{data}) \tag{3-1}$$

可以解释为生成出的图片数据接近真实人脸数据。生成器生成的内容和真实数据之间的散度最小。在理想状态下，当散度归零就意味着两个向量的空间完全重合其中$\mathrm{Div}(P_G, P_{data})$是$P_G$和$P_{data}$的散度。

生成器的训练过程可以视为对目标函数求解，即：

$$G^* = \arg\min_G \mathrm{Div}(P_G, P_{data}) \tag{3-2}$$

在第一轮训练中，通过高斯分布为判别器和分类器分配系数θ_0和$\theta_0{}'$,通过高斯分布给出先验概率x_0。将x_0输入生成器 G 之中产生第一批低质量的图片向量$\tilde{x} = P_{G(x_0|\theta_0)}$。

$\tilde{x}$将作为与P_{data}内数据对应的低质量图像，两者构成在第一轮训练中的训练数据集。

3.1.2 判别器函数推导

本文期望判别器可以分别出在混杂数据集中哪些数据来自真实人脸数据，而哪些数据是由生成器 G 所生成的数据，所以训练判别器 D 作为二分类分类器，训练过程使用最小交叉熵法，训练过程中固定 G 的系数θ，所以与 G 相关的数据此时可以视为常数。

因此设中间函数 V 如下：

$$V=E_{x\sim P_{data}}[\log D(x)]+E_{x\sim P_G}\left[\log\left(1-D(x)\right)\right] \tag{3-3}$$

其中 x 是判别器的输入项，$E_{x\sim P_{data}}$表示 x 属于P_{data}的期望，$E_{x\sim P_G}$表示 x 属于P_G的期望。当 x 属于P_{data}的可能性更大，D 会表现出正反馈；当 x 属于P_G的可能性更大，D 会表现出负反馈。

则目标函数可以设置为对该中间函数取最大值，即：

$$\max V(D,G) \tag{3-4}$$

而 D 的训练过程可以理解为对该目标函数求解：

$$D^* = \arg\max_D V(D,G) \tag{3-5}$$

其中$V(D,G)$可以变形为：

$$P_{data}\log D(x)+P_G(x)\log\big(1\text{-}D(x)\big) \tag{3-6}$$

易证该函数在$D^* = P_{data}/(P_G + P_{data})$处存在最大值，代入代入 D*,可知:

$$max_D\ V(D,G)=\text{-}2\log2+2JSD(P_{data}\ ||\ P_G) \tag{3-7}$$

其中 JSD 指 J-S 散度(Jensen-Shannon divergence),这就解决了如何计算两个无法获知其具体空间的函数之间的无法计算散度的问题，而可以计算散度就意味着可以使用梯度下降法来最小化散度。散度就是生成器目标函数
$G^* = \arg\min_G Div(P_G, P_{data})$中的：$Div(P_G, P_{data})$。

3.1.3 生成器函数推导

此时已经具备条件用判别器 D 函数来反推生成器 G 函数。已知$V(D,G) = Div(P_G, P_{data})$，且$D^* = \mathrm{argmax}_D V(D,G)$。

故$G^*=\arg\min_G \max_D V(G,D)$这个函数可以微分后使用梯度下降法求解。

3.1.4 迭代训练

在初始化的第一轮训练之后的每一轮训练之中(训练轮次用 n 表示)：

(1)固定生成器G_n的系数向量θ，更新判别器$D_n \to D_{n+1}$

(2)固定判别器D_{n+1}的系数向量θ'，更新生成器$G_n \to G_{n+1}$

在上述过程中，对判别器 D 的迭代次数需要尽量多。这样可以保证判别器可以准确地判断出一个数据是来自生成器所生成的数据还是来自真实数据。因为随着每一轮训练，生成器的生成内容都会更靠近真实数据，这会导致旧的生成器失效。即

$\max_{D_n} V(D_n, G_n) \neq \mathrm{Div}(P_{G_n}, P_{data})$。所以在每一轮的训练中都需要新的判别器 D 来计算准确的散度。

生成器在每一轮训练中需要迭代尽量少的次数。其原因是当迭代次数过多时，G_{n+1}的取值空间会相较于G_n产生较大的变化，这会导致$\max_{D_{n+1}} V(D_{n+1}, G_{n+1}) \neq \mathrm{Div}(P_{G_{n+1}}, P_{data})$。而在生成器 G 训练的过程中判别器 D 的系数是固定的，所以在训练生成器 G 的过程中迭代次数越多G_{n+1}的函数空间和G_{n+1}的差距就会越大从而使判别器失效导致目标函数不成立。为解决这一问题本文在每一轮训练中只对生成器 G 进行一次迭代。

长远来看这样做并不会明显增加模型整体的训练负担，因为在每一轮迭代中生成器受到反向传播影响的规模越小，其函数空间的变化也越小，判别器 D 的训练时间也会相应减小。

3.2 算法框架优化

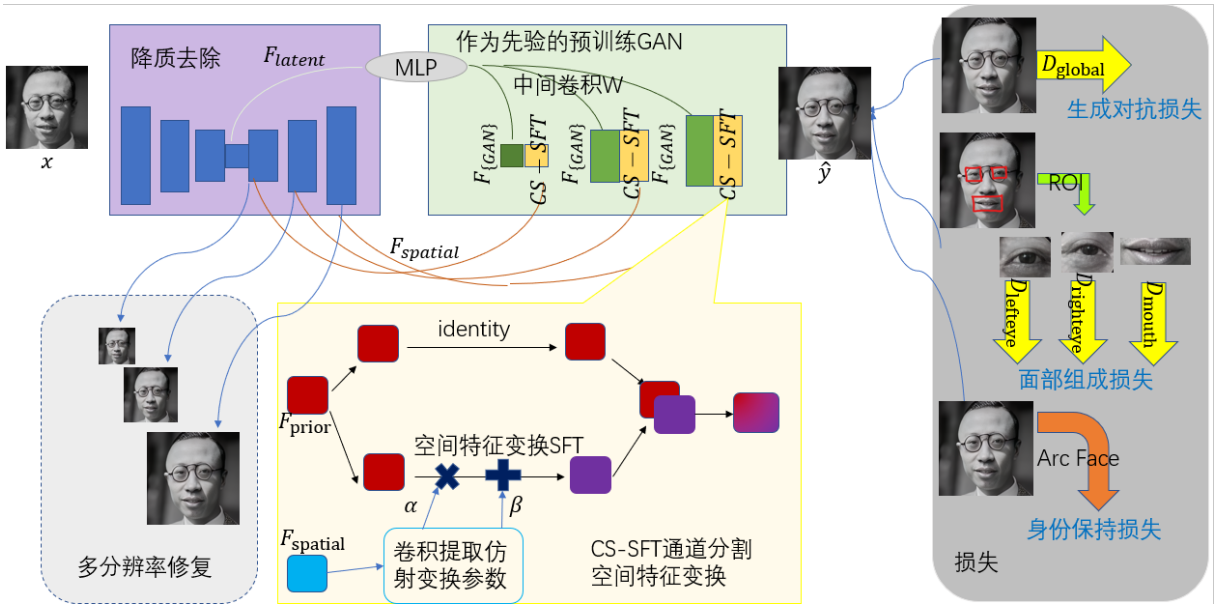

图 3.2 模型优化后框架

在以往的人脸修复研究中，常使用几何脸部先验（geometry facial priors）[14]和参考先验（reference priors）[15]来辅助真实人脸的生成。但这两种方式存在一些不足。

几何脸部先验通常获取自质量极低的输入图像，虽然可以作为一定的指导，诸如眼镜、嘴的相对位置，瞳孔纹理等，但其对真实人脸的生成帮助有限。

参考先验包含了高清晰度人脸和脸部重要部位的字典，这样可以缓解生成结果对低清晰度人脸的依赖。但是高质量的参考的获取难度较高。以及在实际情况中，不同角度、人种、性别等因素，以及眼镜、发饰、帽子等配饰都会对生成过程产生影响，而有限容量的字典会对脸部细节的丰富性和多样性产生限制。

本文在设计过程中参考了 Tencent 研究团队在 GFPGAN 中所做出的优化，使用了生成式脸部先验(Generative Facial Priors)[9]，有效增加了 GAN 算法用作人脸修复时的训练效率和训练成果。

3.2.1 优化技术介绍

(1)降解去除模块:

U-Net[16]最初被作为医学图像领域提取图像特征的一种分割函数，可以将图像分为多个部分并输出相对应的掩码，这些掩码可以用来去除图像中的噪音和伪影。

具体操作是将原有图像分割为潜在特征向量F_{latent}和空间特征向量$F_{spatial}$：

$$F_{spatial},F_{latent}=\text{U-Net}(x) \tag{3-8}$$

其中F_{latent}包含了整个人脸图像的全局信息，$F_{spatial}$包含了人脸图像的局部信息。

(2)生成式脸部先验：

styleGAN[17]是一个基于 GAN 模型衍生出的图像生成模型，其可以根据所输入的低维参数向量生成高维度的图像向量。styleGAN 主要由两个因素影响，分别是风格(style)和噪声(noise)。风格控制图像的姿态、身份特征等内容，噪声控制头发、肤色、皱纹等细节特征。

使用多层感知机将 U-Net 生成的空间特征转换为 styleGAN 所需要的中间卷积：

$$W = \text{MLP}(F_{latent}) \tag{3-9}$$

将中间卷积输入到 styleGAN 中生成每个不同分辨率尺度下的 GAN 特征参数向量F_{GAN}。

$$F_{GAN} = styleGAN(W) \tag{3-10}$$

(3)通道分割空间特征变换：

在每个分辨尺度下，通过卷积变换函数生成仿射变换参数向量，权重α和偏置β：

$$\alpha,\beta = Conv(F_{spatial}) \tag{3-11}$$

通过通道分割空间特征变换(CSSFT)[9]用仿射变换参数向量对 GAN 特征参数向量

进行修饰：

$$F_{output}=CS\text{-}SFT(F_{GAN}|\alpha,\beta)=Contact\left[Identity\left(F^{split0}{}_{GAN}\right),\alpha\odot F^{split1}{}_{GAN}+\beta\right] \quad (3\text{-}12)$$

其中，$F^{split0}{}_{GAN}$和 FGAN 是从 FGAN 在通道内的维度中分离出来的特性，而 Contact[，]表示连接操作。

(4)ROI 目标检测：

本文中使用了 R-CNN[18]中的 ROI 感兴趣区域检测，在本文中主要用于将感兴趣区域固定在左眼、右眼、嘴这些区域来分别检测面部组成损失。

3.2.2 损失函数

设真实图像为y，模型生成图像为$\hat{y}$，用于计算损失函数和计算梯度。

本模型将损失函数分为四个部分：对抗损失L_{adv}、重构损失L_{rec}、面部组成损失L_{comp}、身份保持损失L_{id}。

(1)重构损失：

重构损失用于减少真实图像y和生成图像$\hat{y}$之间的差异。

采用了 L1 损失和 perceptual 损失[19]结合构成重构损失：

$$L_{rec}=\lambda_{l1}\|\hat{y}\text{-}y\|_1+\lambda_{per}\left\|\phi\left(\hat{y}\text{-}\phi(y)\right)\right\|_1 \quad (3\text{-}13)$$

其中λ_{l1}是 L1 损失的权重参数，λ_{per}是 perceptual 损失的权重参数，ϕ是 VGG-19 网络[20]的参数，用于增加网络深度以增加修复效果

(2)对抗损失：

对抗损失用于支持网络生成更真实的面部纹理，采用了和 styleGAN 中类似的逻辑回归损失函数：

$$L_{adv}=\text{-}\lambda_{adv}\, E_{\hat{y}}\, softplus\left(D(\hat{y})\right) \quad (3\text{-}14)$$

其中λ_{adv}是一个超参数，用于控制对抗性损失在总损失中的权重。$E_{\hat{y}}$是对所有生成器生成的图像$\hat{y}$求期望值。softplus是一个平滑的激活函数，它可以将任何实数映射到正实数。D 是判别器。

(3)面部组成损失：

面部组成损失是为了进一步降低面部重要组成成分的损失，本文中使用了左眼、右眼、嘴的局部判别器D_{ROI}来计算面部组成部分分别的特征损失。

而根据已有的研究成果[21]，进一步引入学习鉴别器的风格特征损失可以有效下降

特征匹配损失。本文采用了 Gram 矩阵来计算生成图像的面部组成特征和真实图像的面部组成特征之间的损失。Gram 矩阵通常可以有效地捕捉到纹理信息。通过从判别器中获得来自生成图像和真实图像的多分辨率特征ψ，经过 Gram 函数处理后提取图片中的纹理信息，之后计算两者的特征损失。

$$L_{comp}=\sum_{ROI}\lambda_{local}E_{\hat{y}_{ROI}}\left[\log\left(1\text{-}D_{ROI}(\hat{y}_{ROI})\right)\right]+\lambda_{fs}\|Gram(\psi(\hat{y}_{ROI}))\text{-}Gram(\psi\{(y_{ROI}))\|_1 \quad (3\text{-}15)$$

其中 ROI 是感兴趣区域的组件集合{左眼，右眼，嘴}，D_{ROI}是面部组成判别器。$E_{\hat{y}_{ROI}}$为 ROI 集合中的面部组成在生成图像中的期望。λ_{local}和λ_{fs}分别表示局部判别损失和特征风格损失的损失权重。

(4)身份保持损失：

身份保留损失属于风格损失的一种，常被用于人脸识别。类似于与 perceptual 损失，本文根据输入人脸的特征嵌入定义身份保持损失。采用了预训练的 ArcFace 模型[22]来代替这一部分的判别器 D，该模型可以捕获最突出的身份识别特征：

$$L_{id}=\lambda_{id}||\mu(\hat{y})-\mu(y)||_1 \quad (3\text{-}16)$$

其中λ_{id}为身份保持损失的权重参数，μ为面部特征提取器 ArcFace。

(5)综合损失：

$$L_{total}=L_{adv}+L_{rec}+Lcomp+L_{id} \quad (3\text{-}17)$$

在训练过程中所使用的权重参数如下。

表 3.1 模型训练权重参数表

参数名	数值	说明
λ_{adv}	0.1	对抗损失权重
λ_{l1}	0.1	11 损失权重
λ_{per}	1	perceptual 损失权重
λ_{local}	1	局部判别损失权重
λ_{fs}	200	特征风格损失的损失权重
λ_{id}	10	身份保持损失权重

第 4 章　前端设计与系统测试

本系统基于 PySimpleGUI 设计了图形化界面，本部分将叙述图形化界面的设计结构和思路。

为了测试本系统的修复性能，就本系统的人脸修复成果进行了一系列视觉对比测试和可量化指标测试。从视觉和可量化标准两个维度与同类型算法的性能进行对比。

4.1 前端设计

系统整体工作流程图如图 4.1 所示。GUI 界面的主要功能是为用户提供了一个简明易用的路径选定界面，可以省去复杂的命令行输入。在人脸修复完成后，为用户展示修复前后人脸图片的对比图。

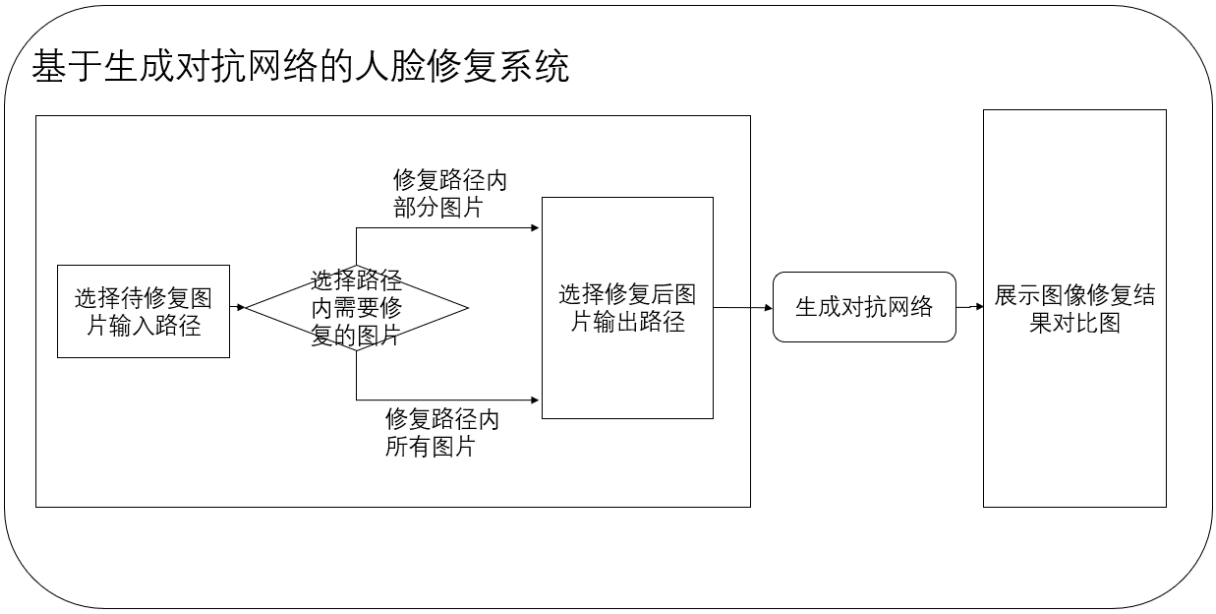

图 4.1 系统整体结构功能

图片输入路径选择界面如图 4.2 所示。

图 4.2 输入路径选择界面

选择路径后可选择修复该路径下全部图片或者部分图片，具体如图 4.3 所示。

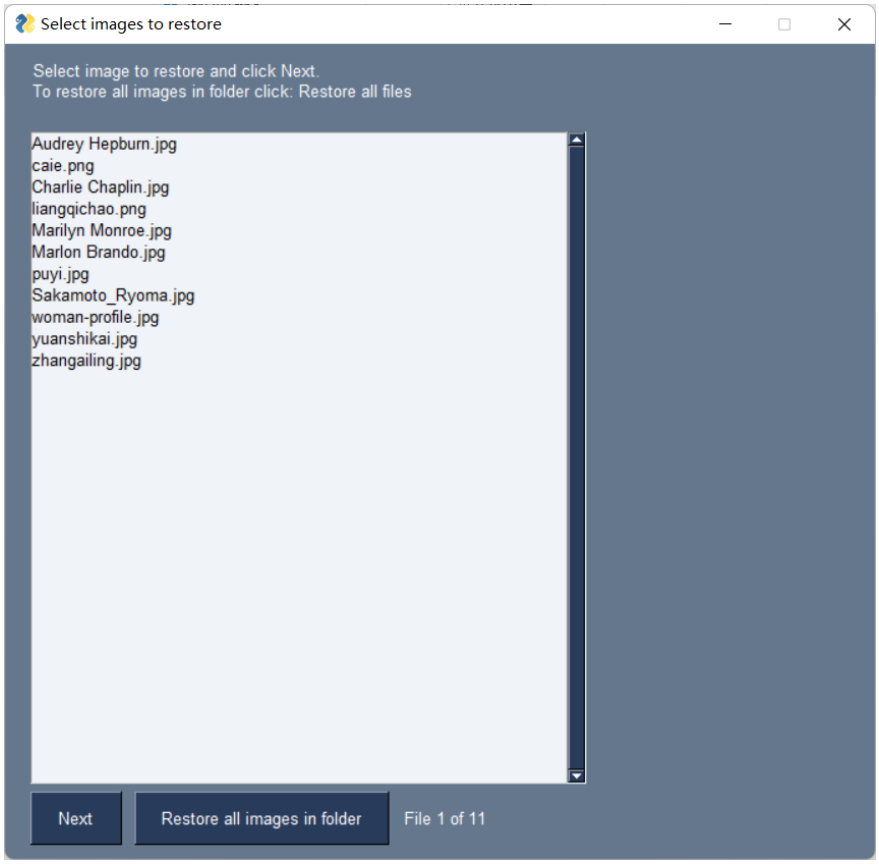

图 4.3 路径下图片选择界面

此处点击 Restore all images in folder 即可修复所有当前路径下的图片。这之后需要选择修复后人脸图片的存放路径，如图 4.4 所示。

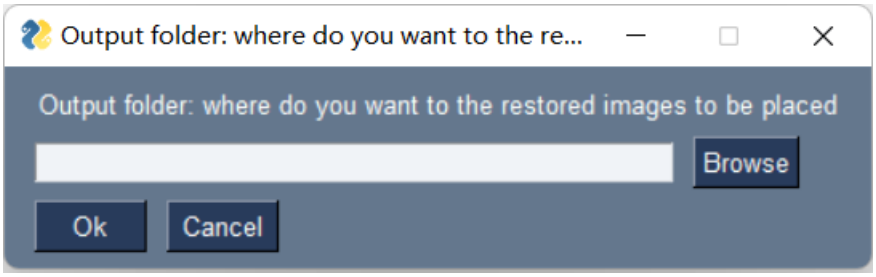

图 4.4 输出路径选择界面

所有路径选定后会进入确认界面，显示用户之前所选定的输入路径和输出路径，并询问是否循行修复程序。此处点击 Run restoration 后会进入修复会调用 GAN 模型进行人脸修复，修复时间由所需要修复的图片数量决定。修复完成后将展示人脸修复成果，具体界面如图 4.5 所示。

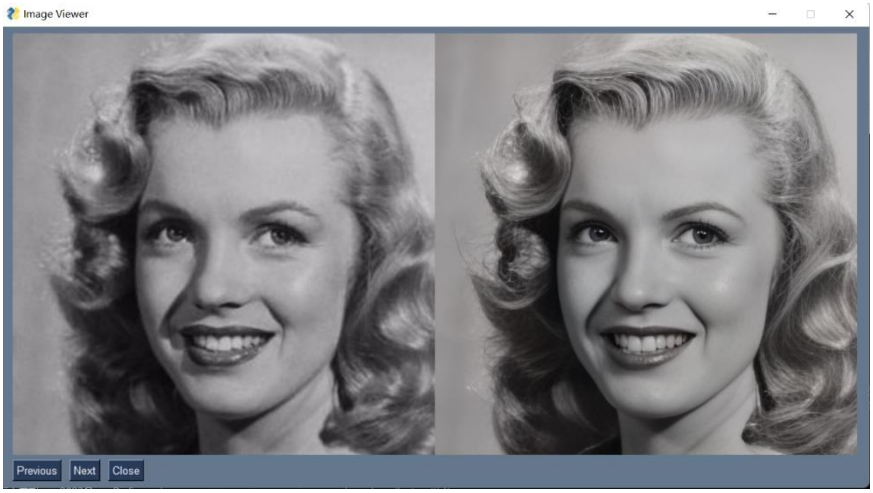

图 4.5 修复结果对比界面

展示界面读取了 output\cmp 路径下所有的修复效果对比图，点击 Previous 可以按顺序切换到当前路径下的上一张图片，点击 Next 可以切换到下一张图片。

如果需要修复前人脸分割图片、修复后人脸分割图片、对比图的图片文件数据作为他用，上述文件分别保存于选定的 output 文件夹下的 cropped_faces、restored_faces 和 cmp 路径下。

4.2 视觉效果对比

将本系统的人脸修复结果与同类型算法对同一张来自真实世界的低质量人脸图片

的修复效果进行对比，其中作为对比的算法有 HiFaceGAN[23]、DFDNet[24]、Wan et al.[25]、PULSE[26]、GFP-GAN(Tencent 1.0v)[9],具体效果如图 4.6 所示。放大可观察图片细节。

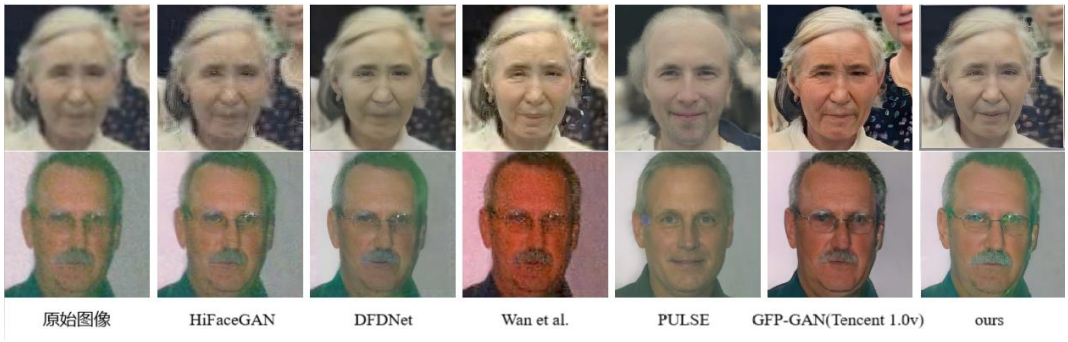

图 4.6 多种算法修复效果对比

虽然相较于 PULSE 以及之前的人脸修复算法相比，本系统在身份保持、伪影以及噪音方面更好，但相对于 GFP-GAN(Tencent 1.0v)缺少了色彩增强模块，与 GFP-GAN(Tencent 1.0v)相比在部分细节的处理，如眼镜边框，发丝等部分出现了边界模糊和本不属于原图结构的噪音，但鉴于所使用的硬件环境和迭代次数均不及 Tencent 团队，目前的生成效果相较于其他模型是可以接受的。

4.3 量化标准对比

相较于肉眼观察，可量化标准更能体现图片修复的效果。

本文采用 SSIM[13]、PSNR、LPIPS[14]三项常用的图像修复质量评判标准。

(1)峰值信噪比：

PSNR(Peak Signal to Noise Ratio，峰值信噪比)[13]是一种基于 MSE(mean squared error，均方误差)的定义，一般作为衡量经过未知退化的图像相较于原图像的失真程度。值越大代表失真越小。在针对本系统的测试中，低质量人脸图像作为遭遇未知退化的图像。

PNSR 的函数定义为：

$$PNSR = 10\,lg\,\frac{(2^n-1)^2}{MSE} \tag{4-1}$$

其中 MSE 的函数定义为：

$$\mathrm{MSE}=\frac{1}{\mathrm{H}\times\mathrm{W}}\sum_{j=1}^{H}\sum_{j=1}^{W}\left(\mathrm{X(i,j)-Y(i,j)}\right)^2 \tag{4-2}$$

H 代表图像高度，W 代表图像宽度，n 为每像素的 bite 数。

(2)图像相似性：

SSIM(Structrual Similarity Index Metric，结构相似性)，一般用于衡量两个图片x和y的相似程度，取值范围在 0~1 之间，结果越接近 1，说明图像越相似。其函数定义为：

$$\mathrm{SSIM(x,y)}=\frac{\left(2\mu_x\mu_y+C_1\right)\left(2\sigma_x\sigma_y+C_2\right)}{\left(\mu_x^2+\mu_y^2+C_1\right)\left(\sigma_x^2+\sigma_y^2+C_2\right)} \tag{4-3}$$

其中μ_x和μ_y为两个图像经过降维操作后的平均灰度；σ_x和σ_y分别为两幅图像的标准差，$2\sigma_x\sigma_y$为协方差。C_1和C_2仅作为常数避免分母为 0.

(3)学习感知图像相似性：

学习感知图像相似性[14]使用了 CNN(Convolutional Neural Network，卷积神经网络)来学习感知相似度，取值范围在 0~1 之间，数值越接近 0，图像越相似。其计算方法需要深度学习框架实现，较为复杂，故不在此赘述。

其完整的计算框架被封装在 lpips 库中，本框架需要 NVIDA CUDA 框架支持。

4.4 量化标准测试流程及结果

本测试为计算三项数值化指标，基于 python 编写了计算程序，通过获取未修复人脸图像路径和修复后人脸图像路径传入数据，引入 numpy 函数和 lpips.LPIPS 函数进行计算，将计算结果存入 csv 文件。

数据显示，在修复不同质量的遭受未知退化的人脸图片时，在 SSIM 和 LPIPS 表现较为稳定。数据在折线图上的表现如下。

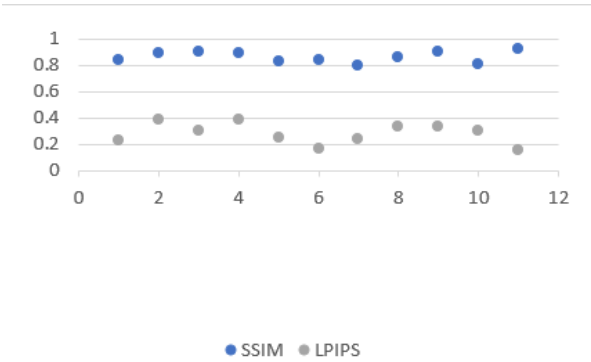

图 4.7 SSIM 和 LPIPS 数据散点图

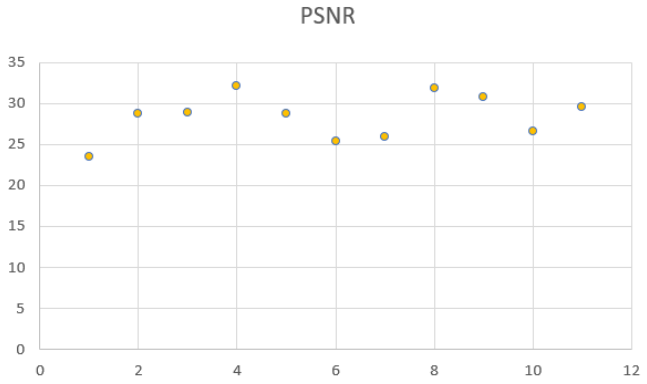

图 4.8 PSNR 数据散点图

与同类型算法的横向对比数据如表 4.1 所示。

表 4.1 与同类型算法的横向对比

算法名称	PSNR↑	SSIM↑	LPIPS↓
RGAN*[27]	27.24	0.7533	0.4159
ESEGAB*[28]	23.74	0.6319	0.4127
Super-FAN*[29]	25.58	0.7033	0.4791
GFP-GAN(Tencent v1.0)*[9]	25.04	0.6744	0.3653
本系统	28.41	0.8593	0.2785

根据对不同图像质量的人脸照片的修复结果进行的对比显示，当原始图像的质量过差，如噪音过多、图片过曝、照片物理结构损坏、图片中存在多张人脸等以上情况均会对本系统的修复效果产生影响。在上述情况下，本系统的修复效果相较于 GFP-GAN(Tencent 1.0v)较差。但对于图片细节缺失不过于严重的人脸图片，本系统可以在视觉效果上达到和 GFP-GAN(Tencent 1.0v)相当的水平，甚至在某些量化评价标准上优于 GFP-GAN(Tencent 1.0v)。

第 5 章　总结及展望

本系统是基于 GAN 和 GFPGAN 的一款真实人脸修复系统。系统主要包括了生成器和判别器这两个神经网络，并基于 GFPGAN 的设计优化，通过借鉴许多近三年来优秀的学术研究成果，为 GAN 模型的训练引入了更优秀的预训练生成先验和预训练的判别器，将图像生成框架和图像识别框架通过 CSSFT 进行有机结合，使 GAN 算法在处理盲脸修复这一细分领域的问题时可以拥有更好的效果。相较于以往的同类型算法，本系统在低训练总数下的效果总体上比较优秀。不但体现在直观视觉的效果上，也体现在量化的计算标准上。

基于目前的实现效果可以对本课题的未来发展做出合理展望。如果在更好的硬件设备上提升迭代总次数，理论上可以解决本课题在视觉细节呈现上的不足。例如，本系统在发丝和眼镜边框的修复上往往表现出本不属于原图片的额外噪音。在训练次数更多的情况下这一问题理论上可以得到解决。以及为了对硬件条件限制所造成的训练时间过长的问题做出妥协，本系统不具有色彩增强模块，这导致本系统只能根据原低质量图片给出的颜色进行修复，而无法根据过去训练中获得的知识为人脸添加应有的颜色。虽然这可以提升在部分量化测试上的表现，但并不意味着算法的修复结果在视觉上的表现更好。如果在后续扩展中添加色彩增强模块，就可以做到增强修复后的人脸图像色彩表现，为黑白图片添加色彩。

参考文献

[1] 郭军等.人工智能导论[M].北京邮电大学出版社, 2021.

[2] Szeliski 等美. Richard.计算机视觉[M].清华大学出版社, 2012.

[3] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative Adversarial Networks [J]. arXiv preprint arXiv:1406.2661, 2014.

[4] Nowozin S, Lampert C H. Structured learning and prediction in computer vision[J]. Foundations and Trends® in Computer Graphics and Vision, 2011, 6(3–4): 185-365.

[5] ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing [C]//ICASSP. 2022.

[6] Lim J H, Ye J C. GeometricGAN[EB/OL]. arXiv preprint arXiv:1705.02894, 2017.

[7] Hindupur Avinash. The GAN Zoo [EB/OL]. GitHub, 2022 (2018-5-23) [2023-5-2]. https://github.com/hindupuravinash/the-gan-zoo.

[8] NVIDIA Technical Blog. Scikit-learn Tutorial – Beginner's Guide to GPU Accelerated ML Pipelines [EB/OL]. [2022-10-30]. https://developer.nvidia.com/blog/scikit-learn-tutorial-beginners-guide-to-gpu-accelerated-ml-pipelines/.

[9] Wang X, Li Y, Zhang H, et al. Towards Real-World Blind Face Restoration with Generative Facial Prior [J]. arXiv preprint arXiv:2101.04061, 2021.

[10] PySimpleGUI [EB/OL] (2023-4-19)[2023-5-2]https://pysimplegui.readthedocs.io/

[11] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612.

[12] Zhang R, Isola P, Efros A A, et al. The unreasonable effectiveness of deep features as a perceptual metric[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 586-595.

[13] Karras, T., Laine, S., & Aila, T. A Style-Based Generator Architecture for Generative Adversarial Networks [DB/OL] (2018)[2023-4-20]. https://github.com/NVlabs/ffhq-dataset

[14] Chen Y, Tai Y, Liu X M, 等. Fsrnet: End-to-end learning face super-resolution with facial priors [C]//CVPR. 2018.

[15] Li X M, Liu M, Ye Y T, 等. Learning warped guidance for blind face restoration [C]//ECCV. 2018.

[16] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation [J]. arXiv preprint arXiv:1505.04597, 2015.

[17] Karras T, Laine S, Aila T. A Style-Based Generator Architecture for Generative Adversarial Networks[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 4401-4410.

[18] He K, Gkioxari G, Dollar P, et al. Mask r-cnn [C]//ICCV. 2017.

[19] Johnson J, Alahi A, Fei-Fei L. Perceptual losses for real-time style transfer and super-resolution [C]//ECCV. 2016.

[20] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition [C]//ICLR. 2015.

[21] Wang T C, Liu M Y, Zhu J Y, et al. High-resolution image synthesis and semantic manipulation with conditional gans [C]//CVPR. 2018.

[22] Deng J K, Guo J, Xue N N, et al. Arcface: Additive angular margin loss for deep face recognition [C]//CVPR. 2019.

[23] Yang L B, Liu C, Wang P, et al. Hifacegan: Face renovation via collaborative suppression and replenishment[C]//ACM Multimedia. 2020.

[24] Li X M, Chen C F, Zhou S C, et al. Blind face restoration via deep multi-scale component dictionaries [C]//ECCV. 2020.

[25] Wan Z Y, Zhang B, Chen D D, et al. Bringing old photos back to life [C]//CVPR. 2020.

[26] Menon S, Damian A, Hu S J, et al. Pulse: Self-supervised photo upsampling via latent space exploration of generative models [C]//CVPR. 2020.

[27] Zhang Y L, Li K P, Li K, et al. Image super-resolution using very deep residual channel attention networks [C]//ECCV. 2018.

[28] Wang X T, Yu K, Wu S X, et al. Esrgan: Enhanced super-resolution generative adversarial networks [C]//ECCVW. 2018.

[29] Bulat A, Tzimiropoulos G. Super-fan: Integrated facial landmark localization and super-resolution of real-world low resolution faces in arbitrary poses with gans [C]//CVPR. 2018.

致谢

至此，我的毕业设计已经结束，四年的本科学位攻读也接近了结尾。在毕业设计的完善过程中和过去四年的学习生涯中，我受到了诸位老师对我学业乃至于职业、人生规划上的帮助，在此特别致谢。

首先，我想先感谢我的毕业设计导师——王镇威老师。王镇威老师不仅是我的毕业设计导师，也是将我引入深度学习领域的领路人，我决定将我的研究生阶段的研究方向确定为深度学习领域，很大程度上是因为受到了来自王镇威老师的影响。最初我对人工智能的了解只是来自于一些文章和新闻，只是觉得其功能强大且十分神奇，对其中的运作原理一无所知。在王镇威老师的指导下我第一次接触到了人工智能的算法原理，并且为我后续的学习给出了建设性的意见和建议，对我帮助很大。王镇威老师不仅在讲解专业知识时逻辑清晰，对行业当下的发展前景也有自己独到的见解。与王镇威老师的交流，让我对行业内目前各企业的现状和学术界的发展趋向有了最基本的宏观了解，这些信息对我来讲都极具参考价值。除此之外，王镇威老师在我申请留学的过程中，基于自己的经验为我提出了很多建设性的意见，为我后续成功申请到研究生提供了很大的助力。

这之后，我想感谢王鲜芳老师。王鲜芳老师指导的算法设计与分析课程使我受益匪浅，常常很亲切地为我们解决在学习过程中所遇到的问题。王鲜芳老师对教学一丝不苟，对学生和蔼亲切，作为我校的科研领头人活跃于学校的科研一线，一直是各位同学心目中理想的研究者的榜样。在今后的学习和研究生涯中我也会继续将王鲜芳老师作为我的榜样。

最后，我想感谢王朝云老师。在大二期间我对学习一度丧失信心，自暴自弃。王朝云老师对我在 python 学习过程中的表现给予了许多肯定，让我能够重新建立起对学习的信心和动力。

除了上述的各位老师，还有许多老师给予了我很多帮助，抱歉不能在此一一列举。再次感谢各位老师在四年间给予的帮助！

特别感谢以下内容制作者所提供的有力支持：

- 感谢李宏毅教授，感谢您上传 GAN 和 Machine learning 系列公开课；
- 感谢 B 站 up 主“王木头学科学”对卷积神经网络、反向传播算法、最大似然

估计、梯度下降法等内容的归纳总结；

- 感谢吴恩达教授，感谢您上传 Deep learning 系列公开课；
- 感谢视频主 3Blue1Brown 制作的线性代数、微积分、概率论、深度学习的科普内容。

感谢上述制作者对互联网知识开源所作出的贡献。